

ROTEIRO DE SURVEY

Você está sendo convidado(a) a participar, como voluntário(a), da pesquisa **“Percepções de Profissionais sobre Requisitos de Qualidade de Dados em Sistemas Habilitados por Machine Learning: Um Survey Exploratório”**, realizada por Kevin Pontes, Arthur Cordeiro, Jessica da Silva, Jhefferson Souza, Emanuel Ávila, Marcelo Martins, Hugo Villamizar e Anderson Uchôa.

Nesta pesquisa, nos dedicamos a compreender como os desenvolvedores tratam a qualidade de dados como requisito para sistemas baseados em aprendizado de máquina. Temos o propósito de descobrir desafios e lacunas existentes nessa área. Para isto, convidamos você a colaborar com a nossa pesquisa respondendo às questões a seguir.

Para participar desta pesquisa, você precisa ter mais de 18 anos e já ter atuado no desenvolvimento de software para sistemas baseados em aprendizado de máquina. Sua participação consiste em responder a um questionário online, que levará aproximadamente 15 minutos para ser concluído. Garantimos o sigilo e a confidencialidade de todas as informações fornecidas durante a pesquisa.

O Termo de Consentimento Livre e Esclarecido (TCLE) visa assegurar seus direitos como participante e está disponível neste link. Por favor, leia-o com atenção para entender completamente a proposta da pesquisa. Sua participação é voluntária, e você pode optar por não participar ou retirar seu consentimento a qualquer momento, sem qualquer penalização ou prejuízo.

Após ter recebido esclarecimentos sobre a natureza da pesquisa, seus objetivos e métodos, eu declaro que sou maior de 18 anos e aceito participar por meio do formulário de participação, conforme as disposições da Lei Geral de Proteção de Dados (Lei nº 13.709/2018). Em caso de resposta negativa, o formulário será encerrado, garantindo assim o respeito à autonomia e privacidade dos participantes, conforme estabelecido pela legislação vigente. (Obrigatória)

☐ Aceito participar

☐ Não aceito participar

CARACTERIZAÇÃO GERAL DO PARTICIPANTE

Nessa seção recolheremos informações básicas e dados pessoais para entender um pouco mais sobre o seu perfil.

1) Qual é a sua idade? (Obrigatória)

- ☐ 18-24 anos
- ☐ 25-34 anos
- ☐ 35-44 anos
- ☐ 45-54 anos
- ☐ 55-64 anos
- ☐ 65 anos ou mais
- ☐ Prefiro não dizer

2) Em que país ou estado você reside atualmente? (Obrigatória)

3) Qual o seu gênero? (Obrigatória)

- ☐ Homem
- ☐ Mulher
- ☐ Não-binário, gênero queer ou não-conformidade de gênero
- ☐ Prefiro não responder
- ☐ Outros

4) Qual é o seu nível de escolaridade? (por favor, escolha um) (Obrigatória)

- ☐ Ensino Médio
- ☐ Ensino Superior
- ☐ Especialização
- ☐ Estudante de mestrado
- ☐ Mestrado
- ☐ Estudante de doutorado
- ☐ Doutorado

5) Qual papel melhor descreve suas atividades atuais no desenvolvimento de sistemas baseados em aprendizado de máquina? (por favor, escolha um) (Obrigatória)

- ☐ Desenvolvedor de Software (Backend, front-end, fullstack)
- ☐ Engenheiro de dados
- ☐ Cientista de dados
- ☐ DevOps engineer
- ☐ Product owner
- ☐ Tech manager
- ☐ QA engineer
- ☐ Outro: _____

- 6) Qual é a senioridade do papel que você exerce na equipe? (por favor, escolha um) (Obrigatória)
- () Estagiário
- () Júnior (até 5 anos)
- () Pleno (6 a 9 anos)
- () Sênior (10+ anos)
- 7) Quantos projetos baseados em aprendizado de máquina você já participou? Por favor, forneça a sua melhor estimativa. (Obrigatória)
- _____

CARACTERIZAÇÃO DA EXPERIÊNCIA COM QUALIDADE DE DADOS EM SISTEMAS BASEADOS EM APRENDIZADO DE MÁQUINA

Nesta seção, gostaríamos de saber sua experiência de com qualidade de dados em sistemas baseados em aprendizado de máquina

- 8) Como você classifica seu nível de habilidade em relação às seguintes atividades que envolvem a etapa de processamento de dados em um sistema baseado em aprendizado de máquina? (Obrigatória)

Práticas	Muito alto	Acima da média	Média	Abaixo da Média	Muito baixa	Não se aplica
Limpeza de dados (remoção de duplicatas, preenchimento de valores faltantes, etc.)						
Normalização ou padronização de dados (ajustar escalas de variáveis, transformar variáveis categóricas, etc.)						
Deteção e remoção de outliers						
Integração de múltiplas fontes de dados (união de diferentes datasets,						

resolver inconsistências entre fontes)						
Aplicação de técnicas de transformação de dados (e.g., PCA, codificação de variáveis categóricas)						
Validação de dados (verificação de consistência, precisão e completude)						
Automatização de pipelines de processamento de dados						
Monitoramento da qualidade dos dados em produção (criação de alertas e métricas para qualidade contínua)						
Uso de bibliotecas e ferramentas para processamento de dados (e.g., Pandas, PySpark, Dask)						
Divisão de dados em treino e teste						

PERCEPÇÃO DA QUALIDADE DE DADOS COMO REQUISITO DE SISTEMAS BASEADOS EM APRENDIZADO DE MÁQUINA

Nessa seção buscamos compreender suas perspectivas sobre diferentes características da qualidade de dados para sistemas baseados em aprendizado de máquina.

A qualidade dos dados é um aspecto fundamental para o sucesso de projetos de aprendizado de máquina. Dados de baixa qualidade podem comprometer a precisão, a confiabilidade e a generalização dos modelos treinados, afetando os resultados esperados.

- 9) Para explorar a percepção sobre esse tema, quais são as cinco primeiras palavras que vêm à sua mente quando você pensa na qualidade dos dados como requisito em projetos baseados em aprendizado de máquina? (Obrigatória)**

Palavra 01: _____

Palavra 02: _____

Palavra 03: _____

Palavra 04: _____

Palavra 05: _____

10) Qual é a sua experiência com atividades da Engenharia de Requisitos em seus projetos? Você já participou da definição, análise ou documentação de requisitos? Se sim, pode compartilhar um pouco sobre como foi esse processo? (Obrigatória)

Para responder às próximas perguntas, considere a descrição das seguintes **características da qualidade de dados**:

- **Acurácia:** Refere-se ao grau em que os dados estão corretos, exatos e livres de erros. Isso implica que os valores dos dados representam fielmente a realidade ou as características que se pretende medir ou descrever. Dados precisos evitam erros que podem comprometer os resultados de modelos de aprendizado de máquina ou análises.
- **Compleitude:** Medida de quantos valores esperados estão presentes em um conjunto de dados. Dados completos contêm todas as informações necessárias, sem lacunas que possam afetar a análise ou o treinamento de modelos.
- **Consistência:** Indica que os dados não possuem contradições internas ou entre diferentes fontes. Consistência é essencial para garantir que as mesmas variáveis mantenham os mesmos valores e significados em todo o sistema.
- **Credibilidade:** Refere-se à confiança na fonte de dados. A credibilidade é importante para que os usuários ou sistemas que consomem os dados confiem neles para tomada de decisões.
- **Atualidade:** Reflete o quão recentes e pertinentes são os dados em relação ao momento em que são utilizados. Dados atualizados são críticos em áreas onde as condições mudam rapidamente, como previsão de demanda ou análises financeiras.
- **Acessibilidade:** Refere-se à facilidade com que os dados podem ser obtidos e utilizados por aqueles que precisam deles, garantindo que estejam disponíveis no momento certo, no formato adequado disponível e com os direitos de acesso necessários.

- **Conformidade:** Refere-se ao alinhamento dos dados com normas, regulamentações ou padrões estabelecidos. Por exemplo, dados de saúde precisam estar em conformidade com leis de privacidade como a LGPD ou GDPR.
- **Confiabilidade:** Medida da capacidade dos dados de serem utilizados de maneira consistente e estável ao longo do tempo. Dados confiáveis são aqueles que produzem resultados previsíveis e corretos repetidamente.
- **Eficiência:** Indica a capacidade dos dados de serem processados e utilizados de maneira eficaz, sem sobrecarregar os sistemas. Dados eficientes são estruturados de forma que otimizam o uso de recursos computacionais.
- **Rastreabilidade:** Refere-se à capacidade de seguir o histórico dos dados, desde sua origem até as transformações que ocorreram ao longo do tempo. Isso é importante para auditoria e resolução de problemas.
- **Compreensibilidade:** Avalia o quão facilmente os dados podem ser interpretados e entendidos pelos usuários ou sistemas. Dados compreensíveis têm documentação clara e estruturas padronizadas.
- **Disponibilidade:** Refere-se à capacidade de garantir que os dados sejam acessíveis e utilizáveis sempre que necessário, sem interrupções ou restrições inesperadas. Essa característica é essencial para que sistemas e projetos possam operar de forma contínua e confiável.
- **Recuperabilidade:** Refere-se à capacidade de restaurar os dados após uma falha ou perda. Dados recuperáveis garantem a continuidade das operações em casos de incidentes, como falhas de hardware ou erros humanos.

11) Com base na sua experiência, qual o nível de importância das seguintes características de qualidade dos dados para projetos de sistemas baseados em aprendizado de máquina? (Obrigatória)

Característica	Nada importante	Pouco importante	Neutro	Importante	Muito importante
Acurácia					
Compleitude					
Consistência					
Credibilidade					
Atualidade					
Acessibilidade					
Conformidade					
Confiabilidade					

Eficiência					
Rastreabilidade					
Compreensibilidade					
Disponibilidade					
Recuperabilidade					

12) Para aquelas características no qual você considerou importante, por favor descreva o motivo da sua classificação. (Opcional)

13) Ainda sobre as características de qualidade de dados, como você caracteriza o grau de prioridade de cada característica para projetos de sistemas baseados em aprendizado de máquina? (Obrigatória)

Característica	Não é uma prioridade	Baixa prioridade	Neutro	Alta prioridade	Essencial
Acurácia					
Completude					
Consistência					
Credibilidade					
Atualidade					
Acessibilidade					
Conformidade					
Confiabilidade					
Eficiência					
Rastreabilidade					
Compreensibilidade					

Disponibilidade					
Recuperabilidade					

14) Para aquelas características no qual você considerou prioritária, por favor descreva o motivo da sua classificação. (Opcional)

15) Com base na sua experiência, como você equilibra diferentes características de qualidade de dados, como precisão, compreensibilidade e eficiência computacional, ao desenvolver sistemas baseados em aprendizado de máquina? Descreva situações e decisões em que diferentes características de qualidade precisaram ser conciliadas. (Obrigatória)

16) Como o controle de versão dos dados pode impactar as características de qualidade dos dados em projetos de aprendizado de máquina? (por favor, escolha um) (Obrigatória)

- () Garante a consistência e rastreabilidade dos dados ao longo do tempo, permitindo que mudanças no dataset sejam documentadas e verificadas.
- () Aumenta a quantidade de dados disponíveis, sem necessidade de verificação de consistência entre as versões.
- () Elimina a necessidade de documentar alterações no dataset, pois todas as mudanças são automaticamente aplicadas ao modelo.
- () Reduz a precisão dos dados, pois versões antigas não são mais utilizadas nos modelos.
- () Outro: _____

IMPLEMENTAÇÃO DE REQUISITOS DE QUALIDADE DE DADOS NO PROCESSO DE DESENVOLVIMENTO

Nessa seção buscamos compreender como os requisitos de qualidade de dados são considerados no processo de desenvolvimento de sistemas baseados em aprendizado de máquina.

17) Considerando os projetos de sistemas baseados em aprendizado de máquina dos quais você participou, como a qualidade dos dados é incorporada no processo de desenvolvimento? (múltiplas escolhas possíveis) (Obrigatória)

- ☐ Avaliação inicial durante a coleta e preparação de dados
- ☐ Monitoramento contínuo durante todo o ciclo de vida do modelo
- ☐ Conjuntos de testes são aplicados para validar a consistência, completude e precisão dos dados antes de serem usados no treinamento.
- ☐ Não existe uma estratégia formal para assegurar a qualidade dos dados durante o desenvolvimento.
- ☐ Outro: _____

18) Como você mede o impacto da qualidade dos dados no desempenho do modelo de aprendizado de máquina? (múltiplas escolhas possíveis) (Obrigatória)

- ☐ Testes A/B
- ☐ Análise de métricas de performance (ex.: precisão, recall)
- ☐ Revisão manual dos resultados
- ☐ Outro: _____

19) Com que frequência os requisitos de qualidade de dados são formalmente discutidos durante o desenvolvimento dos projetos de aprendizado de máquina?(por favor, escolha um) (Obrigatória)

- ☐ Todos os dias
- ☐ Pelo menos uma vez por semana, mas não todos os dias
- ☐ Menos de uma vez por semana, mas pelo menos uma vez por mês
- ☐ Menos de uma vez por mês
- ☐ Nunca

20) Como você documenta, e comunica questões relacionadas à qualidade dos dados dentro da sua equipe e com outras partes interessadas? (múltiplas escolhas possíveis) (Obrigatória)

- ☐ Linguagem estruturada (texto)
- ☐ Ferramentas de Gerenciamento de Projetos (Jira, Trello ou Asana)
- ☐ Documentação Centralizada (Sistemas como Confluence, Google Docs ou Notion)
- ☐ Reuniões de Alinhamento
- ☐ Relatórios Periódicos
- ☐ Outro: _____

21) Quais são os principais desafios para garantir a confiabilidade dos dados em projetos de aprendizado de máquina?(múltiplas escolhas possíveis) (Obrigatória)

- ☐ Inconsistência entre diferentes fontes de dados
- ☐ Dados incompletos ou ausentes
- ☐ Falta de padronização nos formatos de dados
- ☐ Dados desatualizados ou não confiáveis
- ☐ Erros introduzidos durante a coleta e processamento

- ☐ Dificuldade na rastreabilidade e versionamento dos dados
- ☐ Falta de ferramentas adequadas para validação da qualidade dos dados
- ☐ Outro: _____

22) Com que frequência você recebe suporte de outros times (ex.: equipe de dados, cientistas de dados) para tratar questões de qualidade de dados? (por favor, escolha um) (Obrigatória)

- ☐ Sempre
- ☐ Frequentemente
- ☐ Ocasionalmente
- ☐ Raramente
- ☐ Nunca